

Methoden und Anwendungen der Optimierung (MAO)

Kapitel 3: Lösungsqualität und Approximation

Univ.-Prof. Dr. Michael Schneider
Christian Schröder

Deutsche Post Chair – Optimization of Distribution Networks (DPO)
RWTH Aachen University

schroeder@dpo.rwth-aachen.de

WS 2017/18



Gesamtgliederung

- 1 Einführung
- 2 Greedy Algorithmen
- 3 **Lösungsqualität und Approximation**
- 4 Lokale Suche
- 5 Metaheuristiken

Agenda

3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

Lösungsqualität und Approximation

Ziele des Kapitels:

- Wissen, wie man die Lösungsqualität einer Heuristik analysieren kann
- Worst-Case-Performance-Analyse an Beispielen erklären und durchführen können
- Unterschiede und Gemeinsamkeiten von Worst-Case-Analyse, Average-Case-Analyse und empirischer Analyse erklären können

Agenda

- 3 Lösungsqualität und Approximation
 - Einführung in die Performance Analyse
 - Worst-Case und Average-Case Analyse
 - Empirische Analyse

Performance Analyse

Ziel: Formalisierung von „möglichst gut lösen“

Gegeben: Eine Instanz $P = (X, c)$ eines Problems Π und eine Heuristik H . Eine optimale Lösung x^* von P erfülle $z_{opt}(P) = c(x^*) > 0$.

Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik H für die Instanz P ist $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$.

Performance Analyse

Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik H für die Instanz P ist $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$.

Bemerkungen:

- Ein Algorithmus A , welcher für alle Instanzen P des Problems Π ein Performance-Verhältnis von 1 hat, ist ein exakter Optimierungsalgorithmus
- Für Minimierungsprobleme ist immer $R_H(P) \geq 1$
- Für Maximierungsprobleme ist immer $R_H(P) \leq 1$

Performance Analyse

Beispiel Next-Fit (aus Kapitel 2):

Instanz $P = (n, C, w)$ mit Behälterkapazität $C = 10$ und $n = 8$
Gegenständen mit folgenden Gewichten:

i	1	2	3	4	5	6	7	8
w_i	2	3	4	3	4	5	6	8

Ablauf:

Iteration	Behälter 1	Behälter 2	Behälter 3	Behälter 4	Behälter 5
1	{1}, 8				
2	{1, 2}, 5				
3	{1, 2, 3}, 1				
4		{4}, 7			
5		{4, 5}, 3			
6			{6}, 5		
7				{7}, 4	
8					{8}, 2
Lösung	{1, 2, 3}, 1	{4, 5}, 3	{6}, 5	{7}, 4	{8}, 2

Performance Analyse

Beispiel (Forts.): In Kapitel 2 hatten wir bereits mittels First-Fit-Decreasing (FFD) eine andere Lösung mit nur 4 Behältern gefunden.

Da die Summe der Gewichte $\sum_{i=1}^8 w_i = 35$ und $C = 10$, sind mindestens $4 = \lceil 3.5 \rceil$ Behälter notwendig, d.h. $z_{opt}(P) = 4$.

Also ist das *Performance-Verhältnis*

$$R_{Next-Fit}(P) = \frac{5}{4} = 1,25.$$

Performance Analyse

Beispiel Greedy-Rucksack (aus Kapitel 2): Rucksackproblem mit $n = 5$ Gegenständen mit Profit $p = (p_1, \dots, p_5) = (3, 7, 2, 8, 4)$ und Gewicht $w = (w_1, \dots, w_5) = (2, 4, 1, 3, 6)$ und ein Rucksack mit Kapazität $C = 9$. Die zugehörige Instanz ist $P = (n, p, w, C) = (5, (3, 7, 2, 8, 4), (2, 4, 1, 3, 6), 9)$.

- Ergebnis des Greedy-Algorithmus: Lösung $x^\top = (x_1, \dots, x_5) = (0, 1, 1, 1, 0)$ mit Profit $7 + 2 + 8 = 17$
- Optimale Lösung: $x^\top = (x_1, \dots, x_5) = (1, 1, 0, 1, 0)$ mit Profit 18.
- *Performance-Verhältnis* der Greedy-Heuristik Gr ist

$$R_{Gr}(P) = 17/18 = 0,9\bar{4}.$$

Performance Analyse

Die Schreibweise $R_H(P)$ macht deutlich, dass hier die Performance der Heuristik H bezogen auf *eine konkrete Instanz* $P \in \Pi$ beschrieben ist.

Man ist aber daran interessiert, *allgemeine Aussagen* über die Heuristik H zu erhalten. Hierzu bieten sich folgende Alternativen an:

- 1 Worst-Case-Analyse
- 2 Average-Case-Analyse
- 3 empirische Analyse, d.h. eine Analyse bezogen auf eine gewählte Menge von Instanzen P

Agenda

3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

Worst-Case-Analyse

Bei der Worst-Case-Analyse interessiert man sich für das *schlechteste Performance-Verhältnis*, welches sich für eine Heuristik H ergeben kann.

Für ein Minimierungsproblem (Maximierungsproblem) heißt

$$R_H := \sup_{P \in \Pi} R_H(P) \quad \left(R_H := \inf_{P \in \Pi} R_H(P) \right)$$

die *Worst-Case-Performance* von H .

Bemerkung: In der Regel gibt es für ein Problem Π unendlich viele Instanzen $P = (X, c) \in \Pi$. Daher gibt es i.Allg. nicht unbedingt *eine* Instanz mit schlechtester Worst-Case-Performance und somit nicht unbedingt ein Minimum/Maximum. Man verwendet also „sup“ (Supremum) statt „max“ und „inf“ (Infimum) statt „min“.

Approximationsalgorithmus

Für eine beliebige Zahl $\varepsilon \geq 0$ ist eine Heuristik H ein **ε -Approximationsalgorithmus**, falls

$$R_H \leq 1 + \varepsilon$$

im Fall der Minimierung und

$$R_H \geq 1 - \varepsilon$$

im Fall der Maximierung gilt.

Beispiel: Für ein Minimierungsproblem und eine Heuristik H gilt:

$$R_H = 1,2 \quad \rightarrow \quad H \text{ ist ein } \frac{1}{5}\text{-Approximationsalgorithmus}$$

Beispiel: Greedy-Algorithmus Rucksackproblem

Beispiel: Wir hatten gerade gesehen, dass der Greedy-Algorithmus Gr für das Rucksackproblem $R_{Gr} \leq 17/18$ erfüllen muss.
Tatsächlich gilt:

Merke:



Die Greedy-Heuristik Gr für das Rucksackproblem kann *beliebig schlechte Lösungen* liefern, d.h. $R_{Gr} = 0$.

Wie?

Beispiel: Greedy-Algorithmus Rucksackproblem II

Zu zeigen: Zu beliebigem $k > 0$ gibt es eine Instanz P_k des Rucksackproblems, so dass $z_{Gr}(P_k) \leq k \cdot z_{opt}(P_k)$ gilt.

- Wähle $n = 2$, $C = M$ mit M ganzzahlig und $M \geq 2/k$,
 $p = (p_1, p_2) = (2, M)$, $w = (w_1, w_2) = (1, M)$.
- Sortierung ist $(1, 2)$, denn $2/1 = 2 > M/M = 1$.
- Folglich liefert Greedy immer die Lösung $(1, 0)$ mit Profit 2.
- **Aber:** Die optimale Lösung ist für $M > 2$ immer $x^* = (0, 1)$ mit Profit M .

$$\text{Also: } R_{Greedy} \leq R_{Greedy}(P_k) = \frac{2}{M} \leq k$$

Beispiel: Greedy-Algorithmus Rucksackproblem III

Beispiel (Forts.): Der Greedy-Algorithmus für das Rucksackproblem lässt sich zu einem Algorithmus *Ext-Gr* mit Worst-Case-Performance $R_{Ext-Gr} = \frac{1}{2}$ (hier gleichbedeutend mit $\frac{1}{2}$ -Approximationsalgorithmus) verbessern. Beweis in (Kellerer u. a., 2004, S. 34).

Algorithmus 1 : Extended-Greedy-Algorithmus für das Rucksack-Problem

// Input: Instanz $P = (n, p, w, C)$

LÖSE P mit dem Greedy-Algorithmus (Ergebnis sei $(\bar{x}_1, \dots, \bar{x}_n) \in \{0, 1\}^n$)

// Ist einzelner Gegenstand k^* besser als Greedy-Lösung?

SETZE $k^* := \arg \max_{j=1, \dots, n} p_j$

if $p^\top \bar{x} < p_{k^*}$ then

 | SETZE $\bar{x} = (0, \dots, 0, 1, 0, \dots, 0)^\top = e_{k^*}$

// Output: $(\bar{x}_1, \dots, \bar{x}_n)$

Worst-Case-Analyse Bin Packing Problem

Übersicht zu Next-/First-/Best-Fit-Heuristiken:

Algorithmus H	Laufzeit	R_H^∞
NF	$\mathcal{O}(n)$	2
FF	$\mathcal{O}(n \log n)$	1,7
BF	$\mathcal{O}(n \log n)$	1,7
NFD	$\mathcal{O}(n \log n)$	1,691...
FFD	$\mathcal{O}(n \log n)$	1,222...
BFD	$\mathcal{O}(n \log n)$	1,222...

aus: (Martello und Toth, 1990, S. 224)

Average-Case-Analyse

Manchmal ist man jedoch nicht am Worst-Case, sondern am *Average-Case* interessiert.

In diesem Fall wird eine *Wahrscheinlichkeitsverteilung auf der Menge der Instanzen* definiert und Aussagen über den *Erwartungswert* und die *Varianz der Performance* werden abgeleitet.

Die wesentlichen Schwierigkeiten bei dieser Art von Analyse sind:

- Das Definieren einer sinnvollen Verteilung über einer in der Regel unendlich großen Menge von Instanzen P des Problems Π
- Das Ausrechnen entsprechender Erwartungswerte und Varianzen

Agenda

3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

Empirische Analyse

In der Praxis ist die *empirische Analyse* weit verbreitet. Hier definiert man eine Menge $\mathcal{I} \subset \Pi$ von relevanten Instanzen des Problems Π .

Das *empirische Performance-Verhältnis* ergibt sich als Mittelwert der Performance über diese Instanzen:

$$\bar{R}_H(\mathcal{I}) := \frac{1}{|\mathcal{I}|} \sum_{P \in \mathcal{I}} R_H(P)$$

Ebenfalls relevant sind die maximale Abweichung,

$$\max_{P \in \mathcal{I}} R_H(P)$$

und die empirische Varianz der Abweichung,

$$\frac{1}{|\mathcal{I}| - 1} \sum_{P \in \mathcal{I}} (R_H(P) - \bar{R}_H(\mathcal{I}))^2.$$

Empirische Analyse

Beispiel: Man generiert zufällig oder speichert aus realen Anwendungen heraus eine (große) Anzahl von Benchmark-Instanzen P zu Definition von \mathcal{I} .

Die *maximale Abweichung* und *empirische Varianz* sind maßgebend für die *Robustheit* einer Heuristik.

Eine Heuristik kann als robust bezeichnet werden, wenn die Varianz der Performance gering ist und die maximale Abweichung nicht wesentlich vom Mittelwert der Performance verschieden ist.

Zur Vertiefung...



- (Grünert und Irnich, 2005), Abs. 3.8 (bis S. 190)
- (Kellerer u. a., 2004), Abs.2.5 und 2.6
- (Martello und Toth, 1990), Abs. 8-8.2

- [Grünert und Irnich 2005] Grünert, T. ; Irnich, S.: *Optimierung im Transport Band I: Grundlagen*. Aachen : Shaker Verlag, 2005
- [Kellerer u. a. 2004] Kellerer, H. ; Pferschy, U. ; Pisinger, D.: *Knapsack problems*. Berlin : Springer, 2004
- [Martello und Toth 1990] Martello, S. ; Toth, P.: *Knapsack Problems: Algorithms and Computer Implementations*. New York : Wiley, 1990 (Wiley Interscience Series in Discrete Mathematics and Optimization)