

# Methoden und Anwendungen der Optimierung (MAO)

## Kapitel 3: Lösungsqualität und Approximation

Univ.-Prof. Dr. Michael Schneider  
Christian Schröder

Deutsche Post Chair – Optimization of Distribution Networks (DPO)  
RWTH Aachen University

[schroeder@dpo.rwth-aachen.de](mailto:schroeder@dpo.rwth-aachen.de)

WS 2017/18



# Gesamtgliederung

- 1 Einführung
- 2 Greedy Algorithmen
- 3 **Lösungsqualität und Approximation**
- 4 Lokale Suche
- 5 Metaheuristiken

## 3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

# Lösungsqualität und Approximation

## Ziele des Kapitels:

- Wissen, wie man die Lösungsqualität einer Heuristik analysieren kann
- Worst-Case-Performance-Analyse an Beispielen erklären und durchführen können
- Unterschiede und Gemeinsamkeiten von Worst-Case-Analyse, Average-Case-Analyse und empirischer Analyse erklären können

- 3 Lösungsqualität und Approximation
  - Einführung in die Performance Analyse
  - Worst-Case und Average-Case Analyse
  - Empirische Analyse

# Performance Analyse

**Ziel:** Formalisierung von „möglichst gut lösen“

# Performance Analyse

**Ziel:** Formalisierung von „möglichst gut lösen“

**Gegeben:** Eine Instanz  $P = (X, c)$  eines Problems  $\Pi$  und eine Heuristik  $H$ . Eine optimale Lösung  $x^*$  von  $P$  erfülle  $z_{opt}(P) = c(x^*) > 0$ .

# Performance Analyse

**Ziel:** Formalisierung von „möglichst gut lösen“

**Gegeben:** Eine Instanz  $P = (X, c)$  eines Problems  $\Pi$  und eine Heuristik  $H$ . Eine optimale Lösung  $x^*$  von  $P$  erfülle  $z_{\text{opt}}(P) = c(x^*) > 0$ .

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{\text{opt}}(P)}$ .



# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein

# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein

# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein exakter Optimierungsalgorithmus

# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein exakter Optimierungsalgorithmus
- Für Minimierungsprobleme ist immer

# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein exakter Optimierungsalgorithmus
- Für Minimierungsprobleme ist immer

# Performance Analyse

## Performance-Verhältnis (Definition)

Das Performance-Verhältnis oder kurz die Performance der Heuristik  $H$  für die Instanz  $P$  ist  $R_H(P) = \frac{z_H(P)}{z_{opt}(P)}$ .

### Bemerkungen:

- Ein Algorithmus  $A$ , welcher für alle Instanzen  $P$  des Problems  $\Pi$  ein Performance-Verhältnis von 1 hat, ist ein exakter Optimierungsalgorithmus
- Für Minimierungsprobleme ist immer  $R_H(P) \geq 1$
- Für Maximierungsprobleme ist immer  $R_H(P) \leq 1$

# Performance Analyse

## Beispiel Next-Fit (aus Kapitel 2):

Instanz  $P = (n, C, w)$  mit Behälterkapazität  $C = 10$  und  $n = 8$   
Gegenständen mit folgenden Gewichten:

$i$	1	2	3	4	5	6	7	8
$w_i$	2	3	4	3	4	5	6	8

## Ablauf:

Iteration	Behälter 1	Behälter 2	Behälter 3	Behälter 4	Behälter 5
1	{1}, 8				
2	{1, 2}, 5				
3	{1, 2, 3}, 1				
4		{4}, 7			
5		{4, 5}, 3			
6			{6}, 5		
7				{7}, 4	
8					{8}, 2
Lösung	{1, 2, 3}, 1	{4, 5}, 3	{6}, 5	{7}, 4	{8}, 2

# Performance Analyse

**Beispiel (Forts.):** In Kapitel 2 hatten wir bereits mittels First-Fit-Decreasing (FFD) eine andere Lösung mit nur 4 Behältern gefunden.



# Performance Analyse

**Beispiel (Forts.):** In Kapitel 2 hatten wir bereits mittels First-Fit-Decreasing (FFD) eine andere Lösung mit nur 4 Behältern gefunden.

Da die Summe der Gewichte  $\sum_{i=1}^8 w_i = 35$  und  $C = 10$ , sind mindestens  $4 = \lceil 3.5 \rceil$  Behälter notwendig, d.h.  $z_{\text{opt}}(P) = 4$ .

# Performance Analyse

**Beispiel (Forts.):** In Kapitel 2 hatten wir bereits mittels First-Fit-Decreasing (FFD) eine andere Lösung mit nur 4 Behältern gefunden.

Da die Summe der Gewichte  $\sum_{i=1}^8 w_i = 35$  und  $C = 10$ , sind mindestens  $4 = \lceil 3.5 \rceil$  Behälter notwendig, d.h.  $z_{opt}(P) = 4$ .

Also ist das **Performance-Verhältnis**

$$R_{Next-Fit}(P) = \frac{5}{4} = 1,25.$$

# Performance Analyse

**Beispiel Greedy-Rucksack (aus Kapitel 2):** Rucksackproblem mit  $n = 5$  Gegenständen mit Profit  $p = (p_1, \dots, p_5) = (3, 7, 2, 8, 4)$  und Gewicht  $w = (w_1, \dots, w_5) = (2, 4, 1, 3, 6)$  und ein Rucksack mit Kapazität  $C = 9$ . Die zugehörige Instanz ist  $P = (n, p, w, C) = (5, (3, 7, 2, 8, 4), (2, 4, 1, 3, 6), 9)$ .

# Performance Analyse

**Beispiel Greedy-Rucksack (aus Kapitel 2):** Rucksackproblem mit  $n = 5$  Gegenständen mit Profit  $p = (p_1, \dots, p_5) = (3, 7, 2, 8, 4)$  und Gewicht  $w = (w_1, \dots, w_5) = (2, 4, 1, 3, 6)$  und ein Rucksack mit Kapazität  $C = 9$ . Die zugehörige Instanz ist  $P = (n, p, w, C) = (5, (3, 7, 2, 8, 4), (2, 4, 1, 3, 6), 9)$ .

- Ergebnis des Greedy-Algorithmus: Lösung  $x^\top = (x_1, \dots, x_5) = (0, 1, 1, 1, 0)$  mit Profit  $7 + 2 + 8 = 17$

# Performance Analyse

**Beispiel Greedy-Rucksack (aus Kapitel 2):** Rucksackproblem mit  $n = 5$  Gegenständen mit Profit  $p = (p_1, \dots, p_5) = (3, 7, 2, 8, 4)$  und Gewicht  $w = (w_1, \dots, w_5) = (2, 4, 1, 3, 6)$  und ein Rucksack mit Kapazität  $C = 9$ . Die zugehörige Instanz ist  $P = (n, p, w, C) = (5, (3, 7, 2, 8, 4), (2, 4, 1, 3, 6), 9)$ .

- Ergebnis des Greedy-Algorithmus: Lösung  $x^\top = (x_1, \dots, x_5) = (0, 1, 1, 1, 0)$  mit Profit  $7 + 2 + 8 = 17$
- Optimale Lösung:  $x^\top = (x_1, \dots, x_5) = (1, 1, 0, 1, 0)$  mit Profit 18.

# Performance Analyse

**Beispiel Greedy-Rucksack (aus Kapitel 2):** Rucksackproblem mit  $n = 5$  Gegenständen mit Profit  $p = (p_1, \dots, p_5) = (3, 7, 2, 8, 4)$  und Gewicht  $w = (w_1, \dots, w_5) = (2, 4, 1, 3, 6)$  und ein Rucksack mit Kapazität  $C = 9$ . Die zugehörige Instanz ist  $P = (n, p, w, C) = (5, (3, 7, 2, 8, 4), (2, 4, 1, 3, 6), 9)$ .

- Ergebnis des Greedy-Algorithmus: Lösung  $x^\top = (x_1, \dots, x_5) = (0, 1, 1, 1, 0)$  mit Profit  $7 + 2 + 8 = 17$
- Optimale Lösung:  $x^\top = (x_1, \dots, x_5) = (1, 1, 0, 1, 0)$  mit Profit 18.
- **Performance-Verhältnis** der Greedy-Heuristik  $Gr$  ist

$$R_{Gr}(P) = 17/18 = 0,9\bar{4}.$$

# Performance Analyse

Die Schreibweise  $R_H(P)$  macht deutlich, dass hier die Performance der Heuristik  $H$  bezogen auf eine konkrete Instanz  $P \in \Pi$  beschrieben ist.

# Performance Analyse

Die Schreibweise  $R_H(P)$  macht deutlich, dass hier die Performance der Heuristik  $H$  bezogen auf **eine konkrete Instanz  $P \in \Pi$**  beschrieben ist.

Man ist aber daran interessiert, **allgemeine Aussagen** über die Heuristik  $H$  zu erhalten. Hierzu bieten sich folgende Alternativen an:

- 1 Worst-Case-Analyse
- 2 Average-Case-Analyse
- 3 empirische Analyse, d.h. eine Analyse bezogen auf eine gewählte Menge von Instanzen  $P$



## 3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

# Worst-Case-Analyse

Bei der Worst-Case-Analyse interessiert man sich für das **schlechteste Performance-Verhältnis**, welches sich für eine Heuristik  $H$  ergeben kann.

# Worst-Case-Analyse

Bei der Worst-Case-Analyse interessiert man sich für das **schlechteste Performance-Verhältnis**, welches sich für eine Heuristik  $H$  ergeben kann.

Für ein Minimierungsproblem (Maximierungsproblem) heißt

$$R_H := \sup_{P \in \Pi} R_H(P) \quad \left( R_H := \inf_{P \in \Pi} R_H(P) \right)$$

die **Worst-Case-Performance** von  $H$ .

# Worst-Case-Analyse

Bei der Worst-Case-Analyse interessiert man sich für das **schlechteste Performance-Verhältnis**, welches sich für eine Heuristik  $H$  ergeben kann.

Für ein Minimierungsproblem (Maximierungsproblem) heißt

$$R_H := \sup_{P \in \Pi} R_H(P) \quad \left( R_H := \inf_{P \in \Pi} R_H(P) \right)$$

die **Worst-Case-Performance** von  $H$ .

**Bemerkung:** In der Regel gibt es für ein Problem  $\Pi$  unendlich viele Instanzen  $P = (X, c) \in \Pi$ . Daher gibt es i.Allg. nicht unbedingt *eine* Instanz mit schlechtester Worst-Case-Performance und somit nicht unbedingt ein Minimum/Maximum. Man verwendet also „sup“ (Supremum) statt „max“ und „inf“ (Infimum) statt „min“.

# Approximationsalgorithmus

Für eine beliebige Zahl  $\varepsilon \geq 0$  ist eine Heuristik  $H$  ein  $\varepsilon$ -**Approximationsalgorithmus**, falls

$$R_H \leq 1 + \varepsilon$$

im Fall der Minimierung und

$$R_H \geq 1 - \varepsilon$$

im Fall der Maximierung gilt.

# Approximationsalgorithmus

Für eine beliebige Zahl  $\varepsilon \geq 0$  ist eine Heuristik  $H$  ein  **$\varepsilon$ -Approximationsalgorithmus**, falls

$$R_H \leq 1 + \varepsilon$$

im Fall der Minimierung und

$$R_H \geq 1 - \varepsilon$$

im Fall der Maximierung gilt.

**Beispiel:** Für ein Minimierungsproblem und eine Heuristik  $H$  gilt:

$$R_H = 1,2 \quad \rightarrow \quad H \text{ ist ein } \frac{1}{5}\text{-Approximationsalgorithmus}$$

# Beispiel: Greedy-Algorithmus Rucksackproblem

**Beispiel:** Wir hatten gerade gesehen, dass der Greedy-Algorithmus  $G_r$  für das Rucksackproblem  $R_{Gr} \leq 17/18$  erfüllen muss.  
Tatsächlich gilt:

# Beispiel: Greedy-Algorithmus Rucksackproblem

**Beispiel:** Wir hatten gerade gesehen, dass der Greedy-Algorithmus  $Gr$  für das Rucksackproblem  $R_{Gr} \leq 17/18$  erfüllen muss. Tatsächlich gilt:



Die Greedy-Heuristik  $Gr$  für das Rucksackproblem kann **beliebig schlechte Lösungen** liefern, d.h.  $R_{Gr} = 0$ .

Wie?



## Beispiel: Greedy-Algorithmus Rucksackproblem II

Zu zeigen: Zu beliebigem  $k > 0$  gibt es eine Instanz  $P_k$  des Rucksackproblems, so dass  $z_{Gr}(P_k) \leq k \cdot z_{opt}(P_k)$  gilt.

- Wähle  $n = 2$ ,  $C = M$  mit  $M$  ganzzahlig und  $M \geq 2/k$ ,  
 $p = (p_1, p_2) = (2, M)$ ,  $w = (w_1, w_2) = (1, M)$ .
- Sortierung ist  $(1, 2)$ , denn  $2/1 = 2 > M/M = 1$ .
- Folglich liefert Greedy immer die Lösung  $(1, 0)$  mit Profit 2.
- **Aber:** Die optimale Lösung ist für  $M > 2$  immer  $x^* = (0, 1)$  mit Profit  $M$ .

$$\text{Also: } R_{Greedy} \leq R_{Greedy}(P_k) = \frac{2}{M} \leq k$$

## Beispiel: Greedy-Algorithmus Rucksackproblem III

**Beispiel (Forts.):** Der Greedy-Algorithmus für das Rucksackproblem lässt sich zu einem Algorithmus **Ext-Gr** mit Worst-Case-Performance  $R_{\text{Ext-Gr}} = \frac{1}{2}$  (hier gleichbedeutend mit  $\frac{1}{2}$ -Approximationsalgorithmus) verbessern. Beweis in (Kellerer u. a., 2004, S. 34).

---

### Algorithmus 1 : Extended-Greedy-Algorithmus für das Rucksack-Problem

---

// Input: Instanz  $P = (n, p, w, C)$

LÖSE  $P$  mit dem Greedy-Algorithmus (Ergebnis sei  $(\bar{x}_1, \dots, \bar{x}_n) \in \{0, 1\}^n$ )

// Ist einzelner Gegenstand  $k^*$  besser als Greedy-Lösung?

SETZE  $k^* := \arg \max_{j=1, \dots, n} p_j$

if  $p^\top \bar{x} < p_{k^*}$  then

    SETZE  $\bar{x} = (0, \dots, 0, 1, 0, \dots, 0)^\top = e_{k^*}$

// Output:  $(\bar{x}_1, \dots, \bar{x}_n)$

---

# Worst-Case-Analyse Bin Packing Problem

## Übersicht zu Next-/First-/Best-Fit-Heuristiken:

Algorithmus $H$	Laufzeit	$R_H^\infty$
NF	$\mathcal{O}(n)$	2
FF	$\mathcal{O}(n \log n)$	1,7
BF	$\mathcal{O}(n \log n)$	1,7
NFD	$\mathcal{O}(n \log n)$	1,691...
FFD	$\mathcal{O}(n \log n)$	1,222...
BFD	$\mathcal{O}(n \log n)$	1,222...

aus: (Martello und Toth, 1990, S. 224)

# Average-Case-Analyse

Manchmal ist man jedoch nicht am Worst-Case, sondern am **Average-Case** interessiert.

In diesem Fall wird eine **Wahrscheinlichkeitsverteilung auf der Menge der Instanzen** definiert und Aussagen über den **Erwartungswert** und die **Varianz der Performance** werden abgeleitet.

Die wesentlichen Schwierigkeiten bei dieser Art von Analyse sind:

- Das Definieren einer sinnvollen Verteilung über einer in der Regel unendlich großen Menge von Instanzen  $P$  des Problems  $\Pi$
- Das Ausrechnen entsprechender Erwartungswerte und Varianzen

## 3 Lösungsqualität und Approximation

- Einführung in die Performance Analyse
- Worst-Case und Average-Case Analyse
- Empirische Analyse

# Empirische Analyse

In der Praxis ist die **empirische Analyse** weit verbreitet. Hier definiert man eine Menge  $\mathcal{I} \subset \Pi$  von relevanten Instanzen des Problems  $\Pi$ .

# Empirische Analyse

In der Praxis ist die **empirische Analyse** weit verbreitet. Hier definiert man eine Menge  $\mathcal{I} \subset \Pi$  von relevanten Instanzen des Problems  $\Pi$ .

Das **empirische Performance-Verhältnis** ergibt sich als Mittelwert der Performance über diese Instanzen:

$$\bar{R}_H(\mathcal{I}) := \frac{1}{|\mathcal{I}|} \sum_{P \in \mathcal{I}} R_H(P)$$

# Empirische Analyse

In der Praxis ist die **empirische Analyse** weit verbreitet. Hier definiert man eine Menge  $\mathcal{I} \subset \Pi$  von relevanten Instanzen des Problems  $\Pi$ .

Das **empirische Performance-Verhältnis** ergibt sich als Mittelwert der Performance über diese Instanzen:

$$\bar{R}_H(\mathcal{I}) := \frac{1}{|\mathcal{I}|} \sum_{P \in \mathcal{I}} R_H(P)$$

Ebenfalls relevant sind die maximale Abweichung,

$$\max_{P \in \mathcal{I}} R_H(P)$$

und die empirische Varianz der Abweichung,

$$\frac{1}{|\mathcal{I}| - 1} \sum_{P \in \mathcal{I}} (R_H(P) - \bar{R}_H(\mathcal{I}))^2.$$



# Empirische Analyse

**Beispiel:** Man generiert zufällig oder speichert aus realen Anwendungen heraus eine (große) Anzahl von Benchmark-Instanzen  $P$  zu Definition von  $\mathcal{I}$ .

# Empirische Analyse

**Beispiel:** Man generiert zufällig oder speichert aus realen Anwendungen heraus eine (große) Anzahl von Benchmark-Instanzen  $P$  zu Definition von  $\mathcal{I}$ .

Die **maximale Abweichung** und **empirische Varianz** sind maßgebend für die **Robustheit** einer Heuristik.

Eine Heuristik kann als robust bezeichnet werden, wenn die Varianz der Performance gering ist und die maximale Abweichung nicht wesentlich vom Mittelwert der Performance verschieden ist.

## Zur Vertiefung...



- (Grünert und Irnich, 2005), Abs. 3.8 (bis S. 190)
- (Kellerer u. a., 2004), Abs. 2.5 und 2.6
- (Martello und Toth, 1990), Abs. 8-8.2

- [Grünert und Irnich 2005] Grünert, T. ; Irnich, S.: *Optimierung im Transport Band I: Grundlagen*. Aachen : Shaker Verlag, 2005
- [Kellerer u. a. 2004] Kellerer, H. ; Pferschy, U. ; Pisinger, D.: *Knapsack problems*. Berlin : Springer, 2004
- [Martello und Toth 1990] Martello, S. ; Toth, P.: *Knapsack Problems: Algorithms and Computer Implementations*. New York : Wiley, 1990 (Wiley Interscience Series in Discrete Mathematics and Optimization)